DOSSIÊ DE CONTEXTO — VALIDA SETIC
Pesquisa e proposta de MVP | Documento de transferência de contexto | 30/10/2026

1. FINALIDADE E LIMITES

Este documento resume a conversa de pesquisa sobre o Desafio 1 do Hackathon SETIC e o projeto Valida SETIC. Não é uma transcrição integral. Foi elaborado a partir do material fornecido pelo usuário e da pesquisa discutida na conversa. As referências abaixo são URLs de fontes identificadas na pesquisa, não uma certificação de implantação ou de situação atual. Ao aprofundar alegações, consulte novamente as fontes originais. Propostas técnicas são sugestões, não decisões oficiais da SETIC.

2. CONTEXTO DO USUÁRIO E OBJETIVO

A equipe é formada por estudantes do primeiro semestre. O objetivo é entregar um MVP pequeno, funcional, demonstrável e compatível com a experiência da equipe em FastAPI e SQLAlchemy. O usuário quer compreender o problema, os antecedentes institucionais e os limites das alegações de impacto antes de desenvolver e apresentar a solução.

3. DESAFIO OFICIAL: QUALIDADE DE DADOS

Fonte principal: PDF fornecido pelo usuário, “Desafios-Hackathon-SETIC_Oficial.pdf”, páginas físicas 2 a 4, incluindo apresentação e Desafio 1.
Objetivo: verificar e padronizar dados antes da gravação, apesar de sistemas com tecnologias e regras diferentes. Uma camada central mantém regras reutilizáveis, retorna aprovação ou bloqueio e explica o erro.
Exemplos: datas, CPF, telefone, e-mail, municípios e valores. A CAGD define e atualiza as regras.
Abordagens permitidas: API central chamada pelos sistemas OU validação no próprio banco. Cada equipe escolhe uma.
Dado inválido: bloquear o registro e retornar erro. O consumidor decide como apresentar e tratar a resposta.
Dados antigos: fora do escopo. Não prometer saneamento do histórico.
Restrições: integração com legados com pouca alteração, diversidade tecnológica, desempenho e minimização de dados pessoais.
Resultados desejados: regras centralizadas, validação antes da gravação, erros com campo/regra/formato esperado e painel de erros por sistema e campo.
Critérios: aplicabilidade real, facilidade de integração, clareza para o usuário e demonstração com dados de exemplo. Usar exclusivamente dados fictícios na demonstração.

4. MVP FORNECIDO PELO USUÁRIO: VALIDA SETIC

Stack proposta: Python + FastAPI; Pydantic e funções Python para entradas e validações; SQLite e SQLAlchemy para configurações e cadastros fictícios; HTML, CSS, Bootstrap e JavaScript com fetch; Swagger do FastAPI; Git e GitHub.
Tela inicial: nome, CPF, e-mail e data de nascimento.
Nome: obrigatório e não formado apenas por espaços.
CPF: formato e dígitos verificadores válidos.
E-mail: formato válido.
Nascimento: data existente e não futura.
Limite explícito: essas verificações não comprovam identidade, existência da caixa de e-mail nem veracidade dos dados.
Fluxo: formulário → backend do cadastro → API central de validação → grava ou bloqueia.
O backend do cadastro precisa respeitar o resultado. Uma API isolada não impede gravações por caminhos que a ignoram.
Configuração CAGD: tela simples para mudar a obrigatoriedade dos campos. Configurações no SQLite; algoritmos técnicos permanecem em funções Python. Não há editor genérico de regras no MVP.
Endpoints propostos: POST /validar; POST /cadastros; GET /regras; PUT /regras/{campo}.
Demonstração: enviar e-mail inválido e data impossível; mostrar erros e ausência do registro no banco; corrigir e salvar; alterar obrigatoriedade e provar a nova regra.
Se houver tempo: segundo formulário representando outro sistema usando o mesmo serviço.
A proposta do usuário prioriza concluir o fluxo antes de gráficos/painel. Atenção: o painel está entre os resultados desejados no desafio; adiar é uma decisão de recorte, não significa que deixou de ser solicitado.

5. VALIDAÇÃO, PADRONIZAÇÃO E COERÊNCIA

Validação pergunta se o valor atende à regra. Padronização converte para uma representação definida, sem adivinhar ou inventar informação.
Exemplos sugeridos: remover espaços nas extremidades de nomes; remover separadores permitidos de CPF antes de verificar dígitos; aceitar uma data no formato publicado e convertê-la para representação interna definida.
Não transformar uma data impossível em outra data. Não inferir silenciosamente datas ambíguas como 03/04/05. Não remover acentos de nomes sem necessidade definida.
Sugestão: a resposta aprovada pode incluir dados_padronizados; o consumidor deve salvar esses valores, não a entrada original.
“Primeiro e segundo nível” foi uma explicação didática do assistente, não classificação oficial da SETIC. Primeiro: campo isolado (data existente). Segundo: relações entre campos/registros (fim anterior ao início, duplicidade, referência inexistente ou vínculo indevido). Isso não exige implementar regras de férias do SID no MVP.

6. ANTECEDENTES INSTITUCIONAIS ENCONTRADOS

SID: estudo “Avaliação técnica da qualidade dos dados do SID”, de 27/01/2022. Identificou duplicidades, incoerências nos períodos de férias, portarias sem vínculo, ausência de auditoria e operações que não consideravam certas condições.
Foram citados 63.934 solicitações e 1.752 portarias: números históricos do estudo, não volumes atuais. A pesquisa não fornece uma taxa atual de erro ou perda de eficiência. Riscos de pagamentos indevidos não comprovam prejuízo efetivamente ocorrido.
PDTIC 2024–2027: a versão consultada contém iniciativas ligadas a padrões técnicos para dados, pipeline de alterações em bases, dados abertos e diretrizes data-driven. É conexão estratégica, não especificação pronta da arquitetura do MVP.
Notícia oficial de abril de 2026: associa a IN nº 5/2026 a diretrizes orientadas por dados, coleta responsável, segurança, indicadores e integração. Na conversa, a notícia foi consultada; não se atribuem artigos específicos à norma sem ler seu inteiro teor.
Data Lake SETIC: documentação de projeto para centralizar e integrar dados, inicialmente com foco em RH, apoiar compartilhamento, controles de qualidade e análise. É complementar à prevenção na entrada. Não comprova que todas as etapas estejam implantadas; não permite afirmar que o projeto fracassou ou que já bloqueia cadastros na origem.
Governança: página institucional identifica a Portaria nº 180/2023 como instituidora do Sistema de Governança da SETIC.

7. DIFERENÇA ENTRE DATA LAKE E VALIDA SETIC

Data Lake centraliza dados para integração e uso analítico. O Valida SETIC centraliza regras e a decisão de validação antes de salvar nos sistemas de origem.
Fluxo possível, não confirmado como arquitetura existente: cadastro → validação → banco de origem → integração posterior com Data Lake.
Não apresentar o MVP como substituto de um Data Lake nem alegar que a iniciativa anterior tentou exatamente o mesmo serviço.

8. CASOS E TECNOLOGIAS COMPARÁVEIS

eSocial: referência pública de esquemas, leiautes, catálogo identificado de regras, rejeições e validação em etapas. Tem processamento por lotes/eventos; não é arquitetura idêntica ao cadastro síncrono.
JSON Schema: base declarativa para tipos, campos, padrões e condições. Não cobre sozinho todas as regras semânticas. O comportamento de format deve ser verificado no validador; em especificações modernas pode atuar como anotação.
Kong Request Validator/OAS Validation: validações antes do serviço de destino ou contra OpenAPI. Cobertura depende de as requisições passarem pelo gateway. Verificar licença, versão e tipos de conteúdo antes de propor adoção.
PostgreSQL: CHECK, NOT NULL e FOREIGN KEY protegem a persistência. CHECK não substitui automaticamente NOT NULL. Portabilidade entre bancos diferentes exige trabalho adicional.
Confluent Schema Registry: referência de catálogo, versionamento e compatibilidade de esquemas. Contratos podem incluir regras adicionais. Validação de ID de esquema no broker não significa inspeção completa dos valores. Há recursos comerciais.
Great Expectations: expectativas e validação de conjuntos de dados; não bloqueia automaticamente todas as gravações de sistemas externos.
Deequ/Amazon: verificações e métricas em grande escala sobre Spark; referência de barreira de qualidade em pipelines,

não escolha obrigatória para cadastro individual.
IBGE: API de localidades é referência oficial para municípios. Cache/cópia local sincronizada é sugestão arquitetural, não regra do edital.

9. PRIVACIDADE E LIMITES OPERACIONAIS

LGPD: qualidade dos dados e necessidade são princípios distintos e complementares. Uma API não torna toda a organização automaticamente adequada à lei.
Recomendações: não registrar payloads pessoais por padrão; métricas agregadas por sistema, campo e regra; restringir administração; documentar retenção; distinguir erro de validação, indisponibilidade e erro interno.
Autenticação/autorização, política de indisponibilidade, latência, volumes e integração de produção ainda não foram definidos na conversa. Não apresentar o protótipo como serviço pronto para produção.

10. PERCENTUAL DE PERDA DE EFICIÊNCIA

Conclusão acordada: não há dados suficientes nas fontes discutidas para afirmar uma porcentagem confiável de perda de eficiência da SETIC.
O edital documenta retrabalho e inconsistências, mas não informa tempo gasto, quantidade atual de erros ou comparação antes/depois. Volume histórico de registros não é taxa de erro.
Taxa de cadastros com erro ≠ porcentagem de eficiência perdida.
Indicadores possíveis: registros com erro / total de registros; tempo de retrabalho / tempo total; redução de tempo total para concluir a mesma tarefa corretamente.
Fórmula proposta: redução de tempo (%) = (tempo sem solução − tempo com solução) / tempo sem solução × 100.
Exemplo SOMENTE HIPOTÉTICO: 60 minutos sem MVP e 45 com MVP = 25% menos tempo total. Retrabalho de 20 para 5 minutos = redução de 75% no retrabalho. Não são resultados reais, nem números da SETIC.
Teste proposto: conjuntos fictícios equivalentes, tarefa final idêntica, tempo incluindo detecção e correção, cenários com/sem MVP, alternância da ordem entre participantes e registro de amostra/metodologia. Um cenário sem qualquer validação não representa necessariamente os sistemas reais, que podem validar parte dos campos.
Para estimativa real: obter volumes mensais, frequência e tipos de erro, tempo de correção, esforço para relatórios, validações já existentes e fração dos problemas detectável pelo MVP.
Não atribuir ao projeto redução de erros que ele não detecta nem usar percentuais genéricos de mercado como medição local.

11. PERGUNTAS AINDA EM ABERTO

Quais sistemas e bancos seriam integrados primeiro? Quais validações já existem? Há catálogo de dados ou gateway reutilizável? Qual latência e disponibilidade são necessárias? Quem pode alterar regras? Como versionar/publicar e reverter? Quais campos podem ser opcionais? O que fazer quando a API cai? Como comprovar que todos os caminhos de escrita obedecem à validação?

12. REFERÊNCIAS IDENTIFICADAS NA PESQUISA

Documento oficial do hackathon: PDF fornecido pelo usuário; anexar separadamente se possível.
SETIC — estudo SID:
https://wiki.setic.ro.gov.br/pt-br/home/spaces/code/gc/estudos/titas5
SETIC — Data Lake:
https://wiki.setic.ro.gov.br/pt-br/home/base_conhecimento/projetos/coge/diversos/proj_datalake
PDTIC consultado:
https://rondonia.ro.gov.br/wp-content/uploads/2025/12/pdtic_2024-2027_rev1.1.4.pdf
Notícia sobre cultura orientada por dados:
https://rondonia.ro.gov.br/cultura-orientada-por-dados-e-instituida-pelo-governo-de-ro-para-modernizar-gestao-publica/
Governança SETIC:
https://rondonia.ro.gov.br/setic/institucional/governanca-de-tic/
eSocial — manual técnico identificado:
https://www.gov.br/esocial/pt-br/documentacao-tecnica/manuais/manualorientacaodesenvolvedoresocialv1-5-01.pdf
eSocial — regras identificadas:

https://www.gov.br/esocial/pt-br/documentacao-tecnica/leiautes-esocial-versao-s-1-3-nt-07-2026-rev-20-10-2026/regras.html
JSON Schema:
https://json-schema.org/learn/getting-started-step-by-step
https://json-schema.org/draft/2020-12/draft-bhutton-json-schema-validation-00
Kong:
https://developer.konghq.com/plugins/request-validator/
https://developer.konghq.com/plugins/oas-validation/
PostgreSQL:
https://www.postgresql.org/docs/current/ddl-constraints.html
Confluent:
https://docs.confluent.io/platform/current/schema-registry/index.html
https://docs.confluent.io/platform/current/schema-registry/schema-validation.html
https://docs.confluent.io/platform/current/schema-registry/fundamentals/data-contracts.md
Great Expectations:
https://docs.greatexpectations.io/docs/core/introduction/gx_overview/
Deequ:
https://aws.amazon.com/blogs/big-data/test-data-quality-at-scale-with-deequ/
IBGE:
https://servicodados.ibge.gov.br/api/docs/localidades
LGPD:
https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709compilado.htm
Referência metodológica de qualidade de dados:
https://www.gov.uk/government/publications/the-government-data-quality-framework/the-government-data-quality-framework-guidance
https://www.gov.uk/government/news/hidden-costs-of-poor-data-quality

13. INSTRUÇÃO SUGERIDA PARA OUTRO CHAT

Use este dossiê como contexto da pesquisa e da proposta. Diferencie exigências do edital, proposta da equipe, sugestões do assistente e fatos de fontes públicas. Não invente métricas ou situação atual de implantação. Mantenha a solução viável para estudantes do primeiro semestre. Consulte as fontes originais ao ampliar alegações e peça o PDF oficial se precisar verificar requisitos literalmente. Ajude a detalhar e implementar o MVP antes de ampliar o escopo.